

Previsão de preço de criptomoeda Bitcoin

Franklin Jordan Ventura Quico¹

¹Instituto de Computação– Universidade Federal Fluminense (UFF)

fventuraq@id.uff.br

Abstract. *This work presents the result of the analysis of the behavior of the digital currency Bitcoin, based on the evolution of the last five years. The analyzed database was made publicly available on the coindesk website, has a total record of 2611 data from October 2013 to the current date, December 12, 2020. This database was used to create a neural network that can predict Bitcoin digital currency's price based on information from the past; for this, we use LSTM - Long short-term memory, a recurring artificial neural network. The results obtained were evaluated using the average percentage error algorithm that generated positive results in the Bitcoin forecast.*

Resumo. *Este trabalho apresenta o resultado da análise do comportamento da moeda digital 'Bitcoin', com base na evolução dos últimos 5 anos. A base de dados analisada foi disponibilizada publicamente pelo site da coindesk, possui um registro total de 2611 dados de outubro de 2013 até a data atual, 12 de dezembro de 2020. Esta base de dados foi utilizada para a criação de um rede neural que pode prever o preço da moeda digital Bitcoin com base em informações do passado, para isso usamos LSTM - Long short-term memory, uma rede neural artificial recorrente. Os resultados obtidos foram avaliados por meio do algoritmo de erro percentual médio que gerou resultados positivos na previsão do Bitcoin.*

1. Introdução

Na última década, a economia mundial mudou drasticamente, a adoção massiva de tecnologias digitais, a internet e os telefones celulares inteligentes transformaram radicalmente o comportamento pessoal, social e econômico em todo o mundo. Em particular, a forma como o valor econômico é criado e transmitido vai mudando dia a dia.

O dinheiro que é o suporte efetivo da atividade econômica e um elemento central da nossa vida cotidiana, está hoje sujeito a um intenso processo de desagregação.

Mais de 10 anos atrás, Satoshi Nakamoto deu origem à moeda digital mais famosa até hoje, o Bitcoin. Esta moeda digital não é a primeira nem a única, existem atualmente mais de 2000 moedas digitais em circulação, com um valor de mercado de cerca de 166,000 milhões de dólares [EIP].

Como as moedas comuns, as criptomoedas também têm um certo grau de volatilidade. Isso porque os consumidores, ao armazenar riquezas e fazer pagamentos internacionais por meio dela, evitam a idiosincrasia da moeda em seu país, o que se contrapõe à burocracia, ao monopólio dos bancos e às regulamentações existentes em seu país. Por

essas razões, os consumidores mudam a volatilidade de sua criptomoeda e isso faz com que o valor da criptomoeda seja tão difícil de prever.

As criptomoedas, entretanto, oferecem uma solução potencial para as economias emergentes digitalizar seus mercados. Alguns países tomaram medidas para adotar moedas digitais (Tunísia, Senegal e Equador), para citar alguns. Embora seja cedo para dizer o quão eficazes eles podem ser ou se são apenas barulho de relações públicas, essas medidas são promissoras [Vol].

Neste artigo é apresentado um modelo computacional para a previsão de moedas digitais, para este caso particular a previsão da moeda digital Bitcoin.

O resto do artigo está organizado da seguinte forma. A seção 2 apresenta o Referencial Teórico sobre os componentes usados para a previsão do bitcoin. A seção 3 descreve os requisitos necessários para prever o Bitcoin. A seção 4 apresenta a criação de uma rede neural para prever Bitcoin. A seção 5 apresenta os resultados obtidos e uma análise dos mesmos. Por fim, a seção 6 apresenta as conclusões e trabalhos futuros.

2. Referencial Teórico

O objetivo deste trabalho é encontrar um algoritmo que auxilie na predição do bitcoin, para isso será necessário aprender vários conceitos que serão usados em conjunto para gerar uma estratégia de investimento em bitcoin.

2.1. Blockchain

Blockchain é essencialmente um registro público descentralizado de todas as transações Bitcoins que foram executadas. Um certo número de transações forma uma unidade de banco de dados, chamada de "bloco", e cada bloco armazena informações sobre o bloco anterior, assim como cada transação armazena informações sobre sua transação anterior. Desta forma, o blockchain permite total transparência dos pagamentos [bit].

A infraestrutura de bloco de Bitcoins introduziu um método revolucionário de armazenamento de dados financeiros que é acessível a qualquer pessoa, totalmente transparente, co-desenvolvido usando código aberto e sem pertencer a nenhuma pessoa ou entidade. Em vez disso, a manutenção do blockchain é feita usando o poder coletivo de milhões de computadores que verificam as transações e as adicionam aos "blocos"[bit].

2.2. Bitcoin

BITCOIN É UMA MOEDA DIGITAL peer-to-peer (peer to peer ou, simplesmente, ponto a ponto), de código aberto, que não depende de uma autoridade central. Entre muitas outras coisas, o que torna o Bitcoin único é o fato de ser o primeiro sistema de pagamento global totalmente descentralizado [Ulrich 1892].

O Bitcoin também pode ser definido pela TI como software de código aberto, apoiado por uma rede de computadores distribuída (ponto a ponto) em que cada nó é simultaneamente um cliente e um servidor. Não existe um servidor central ou qualquer entidade que controle a rede. O protocolo Bitcoin, baseado em criptografia avançada, define as regras de funcionamento do sistema, às quais aderem todos os nós da rede, garantindo um consenso geral sobre a veracidade das transações realizadas e evitando qualquer violação do protocolo [Ulrich 1892].

Em 8 de outubro de 2020, havia mais de 18,5 milhões de bitcoins em circulação. A imagem 1 indica o rápido crescimento da oferta entre 2009 e 2013. Durante 2018 o valor das criptomoedas despencou, o que nos leva a supor que não há garantia de crescimento dessa moeda digital.

Conforme mencionado acima, o Bitcoin é um ativo volátil, com variações diárias que atingem mais de 10%, o que o torna consideravelmente arriscado para investimento e negociação.




Figura 1. Bitcoin total em circulação em outubro de 2020 [bit]

No gráfico 2 podemos observar a evolução dos preços do BTC nos últimos 5 anos, neste podemos observar que durante 2017 o mercado de criptomoedas aumentou 2000%. No entanto, em 2018 esse mercado deu uma guinada e quebrou, causando uma perda em termos de capitalização de cerca de 700 000 milhões de dólares. Uma falha que poderia ter sido explorada investindo em Bitcoin.



Figura 2. Evolução dos preços do bitcoin nos últimos 5 anos [bit]

As causas da queda do preço do Bitcoin em 2018 foram:

- Ofertas ilegais de moedas iniciais (ICOs)
- Lavagem de dinheiro
- Evasão fiscal
- Cyber roubo
- Mudanças nos mercados
- Regulamentação baixa ou inexistente em alguns casos
- Especulação excessiva

Bitcoin se recuperou pouco a pouco até meados de 2018, mas novamente 2019 termina do lado negativo. Nos primeiros meses de 2020, o Bitcoin se recuperou em seu cruzamento com o dólar americano, impulsionado pela incerteza nos mercados tradicionais, já que muitos investidores o veem como um porto seguro [bit].

No entanto, a partir de 26 de fevereiro, tanto o Bitcoin quanto as principais criptomoedas em circulação registraram quedas notáveis devido à fuga de investidores em direção aos mercados portos-seguros tradicionais devido ao temor de um agravamento da crise do coronavírus. É refletido no gráfico com um retângulo vermelho 2.

Um modelo preditivo de Bitcoin ajudaria a apaziguar a incerteza dos investidores, com isso poderia ajudar a gerar estabilidade na criptomoeda.

2.3. LSTM – Long short-term memory

Para a previsão do Bitcoin, usamos um modelo especial de redes neurais artificiais chamado LSTM - Long short-term memory.

LSTM - Long short-term memory ou memória de longo prazo é uma arquitetura de rede neural artificial recorrente usada em campos de aprendizagem profunda. O LSTM é adequado para classificar, processar e prever séries temporais com intervalos de tempo de duração desconhecida. A insensibilidade ao comprimento do espaço dá ao LSTM uma vantagem sobre os RNNs tradicionais. Por exemplo, se quisermos prever a sequência após 1000 intervalos em vez de 10, os modelos tradicionais esquecem o ponto inicial após 1000 intervalos. Mas um modelo LSTM é capaz de "lembrar" devido à sua estrutura celular que ele lembra por vários intervalos de tempo, o que o torna muito útil para previsões de séries temporais.

O LSTM contém unidades especiais chamadas blocos de memória na camada oculta recorrente. Os blocos de memória contêm células de memória que se auto-conectam que armazenam o estado temporário da rede, bem como unidades multiplicativas especiais chamadas portas para controlar o fluxo de informações. Cada bloco de memória na arquitetura original continha uma porta de entrada e uma porta de saída. O gateway controla o fluxo de acionadores de entrada na célula de memória. A porta de saída controla o fluxo de saída das ativações de células para o resto da rede. Mais tarde, a porta do esquecimento foi adicionada ao bloco de memória. Isso abordou uma fraqueza nos modelos LSTM que os impedia de processar fluxos de entrada contínuos que não são segmentados em subsequências. A porta de esquecimento dimensiona o estado interno da célula antes de adicioná-lo como entrada à célula por meio da conexão autorrecorrente da célula, esquecendo ou redefinindo de forma adaptativa a memória da célula. Além disso, a arquitetura LSTM moderna contém conexões de olho mágico de suas células internas para as portas na mesma célula para aprender o tempo preciso das saídas [Sak et al. 2014].

A arquitetura do LSTM é apresentada na Figura 3, onde. *Forget Gate* remove as informações que não são mais úteis no estado da célula, *Input Gate* adicione informações úteis ao estado da célula e *Output Gate* extraia informações úteis do estado da célula atual para ser apresentadas como uma saída.




Figura 3. Arquitetura LSTM [LST]

3. Requisitos

3.1. Software

Para implantar nossa rede neural com eficiência, usaremos uma placa de vídeo (GPU), para rodar os modelos mais rapidamente. Para isso, teremos que realizar os seguintes passos.

- Verifique se nossa placa de vídeo pode usar CUDA
- Baixe CUDA
- Baixe CudNN
- Instale CUDA
- Use GPU tensorflow
- Instale o Python 3

Neste projeto, como etapa adicional, usaremos o IDE para Python "PyCharm". Uma das vantagens adicionais que PyCharm oferece é ser capaz de usar confortavelmente vários consoles Python ao mesmo tempo, caso usemos CUDA, só podemos usar um console.

3.2. Bibliotecas

As bibliotecas que usaremos serão as seguintes.

- **Pandas** é a biblioteca para trabalhar com dataframes (tabelas). Cada dataframe possui linhas e colunas.
- **Numpy** é uma das bibliotecas mais importantes para fazer operações matemáticas.
- **SKLearn** é uma biblioteca de análise de dados para manipulação, preparação e modelagem. Vamos usá-lo para transformar e dimensionar os dados.
- **Matplotlib** é uma biblioteca muito útil para criar gráficos e visualizar resultados.
- **Tensorflow** é uma biblioteca criada pelo Google para projetar e treinar redes neurais.
- **Keras** é a biblioteca que nos ajudará a criar redes neurais de forma mais confortável do que usar o Tensorflow diretamente.
- **Datetime e Dateutil** são bibliotecas para manipulação de datas.

3.3. DataSet

O conjunto de dados a ser trabalhado pertence ao site Coindesk. Coindesk é um site de notícias especializado em bitcoin e moedas digitais. O site foi fundado por Shakil Khan e posteriormente adquirido pelo Digital Currency Group.

Para baixar o conjunto de dados é necessário acessar o site <https://www.coindesk.com/price/bitcoin> neste você terá que selecionar todos os dados conforme mostrado na figura 4, já que por padrão a página web mostra o dados para o dia atual. Depois clicaremos no botão EXPORT DATA onde selecionaremos o formato CSV, isto para trabalhar nos dados.



Figura 4. Bitcoin Price <https://www.coindesk.com/price/bitcoin>

4. Criação da Rede Neural LSTM

4.1. Pré-processamento de dados

Primeiro, carregaremos o conjunto de dados CSV usando o pandas, classificaremos os dados por datas e removeremos as informações extras de que não precisamos. Os dados originais são mostrados na figura 5 como você pode ver existem 2611 registros, cada um com 6 dados.

Posteriormente, converteremos a coluna "Date" em datas reais, pois originalmente no csv ela está no formato string 'texto'.

Agora a coluna "Date" passa a ser o índice e iremos deletar a coluna original "Date".

Os primeiros 1000 registros foram removidos, pois aproximadamente eles diferem muito do comportamento atual do bitcoin, o que pode afetar um pouco nosso modelo. Também trabalharemos com registros anteriores a esta data (2020-12-02).

O número de observação que queremos que o modelo use para prever o próximo valor foi definido e, em seguida, dimensionar os dados usados para SKLearn, em nosso caso, esse valor será "20".

Depois a coluna "Price" foi transformado em um array (lista) com numpy e depois em um array bidimensional. Isso irá gerar um array de $1 \times N$ que vamos mudar para um array de $N \times 1$ usando uma transposição, para isso usaremos Keras.

Por fim, vamos separar os dados em "X" e "y", para isso usamos a ideia de que para cada valor predito são necessários n valores anteriores. Por exemplo, se tivéssemos 8 valores (1, 2, 3, 4, 5, 6, 7, 8) em nosso registro, para prever o valor de Y(7) teríamos que usar o X [1, 2, 3, 4, 5, 6] valores anteriores e para prever o valor de Y(8) teríamos que usar os valores anteriores de X [2, 3, 4, 5, 6, 7]. E por último teremos nosso "Y" e nosso "X" para o treinamento da rede neural.

	Currency	Date	Closing Price (USD)	24h Open (USD)	24h High (USD)	24h Low (USD)
0	BTC	2013-10-01	123.654990	124.304660	124.751660	122.563490
1	BTC	2013-10-02	125.455000	123.654990	125.758500	123.633830
2	BTC	2013-10-03	108.584830	125.455000	125.665660	83.328330
3	BTC	2013-10-04	118.674660	108.584830	118.675000	107.058160
4	BTC	2013-10-05	121.338660	118.674660	121.936330	118.005660
...
2606	BTC	2020-11-30	19382.360586	18201.277248	19850.114487	18201.277248
2607	BTC	2020-12-01	18980.977450	19677.989844	19920.534263	18171.750511
2608	BTC	2020-12-02	19184.897848	18796.748642	19357.164586	18360.231718
2609	BTC	2020-12-03	19464.531705	19220.590149	19607.855344	18899.488685
2610	BTC	2020-12-04	18813.124760	19441.558804	19539.862350	18717.124925

2611 rows x 6 columns

Figura 5. Dados originais

4.2. Treinamento de rede neural

Para treinar nossa rede neural, teremos que criar uma camada de retorno de sequência e uma camada final. Depois uma das partes mais importantes do nosso treinamento será feita, escolhendo a função de minimização e o otimizador.

Em nosso modelo usamos o erro percentual médio para a função de minimização, a razão pela qual esse algoritmo foi escolhido é que, no mundo das finanças, uma previsão é avaliada com uma margem de erro percentual, um exemplo poderia ser que uma previsão com uma margem de erro de 100% é muito ruim.

O otimizador é um algoritmo que tenta minimizar a função de otimização, existem muitos algoritmos de otimização como *SGD*, *RMSprop*, *Adam*, *Adadelta*, *Adagrad*, *Adamax*, *Nadam*, *Ftrl*. no nosso caso, usamos *RMSprop*.

Os dois últimos parâmetros do modelo são os *epochs* e o tamanho do *batch*. Um *epochs* significa que todos os dados serão analisados uma vez. O tamanho do *batch* refere-se ao número de observações que serão analisadas pelo modelo ao mesmo tempo. Em nosso modelo, o *epochs* terão um valor de 200 e o *batch*, um valor de 50.

O resultado do treinamento de nossa rede neural irá gerar um modelo com o qual fazemos previsões, no nosso caso usaremos os dados originais para gerar previsões e avaliar esses resultados com nossos dados originais.

5. Resultados e Análise

5.1. Resultados

Para prever o preço no dia 'X', 20 observações anteriores serão usadas. O resultado da introdução de nossos dados originais ao modelo gerado por nossa rede neural é mostrado na figura 6. Nesta figura você pode ver os dados originais, mas além disso foi adicionada uma coluna "**Predictions**" que mostra as previsões do nosso modelo. Como pode ser visto, as primeiras previsões são as mesmas, já que atrás não existem 20 observações anteriores, mas quanto mais observações houver em nossos dados, o modelo irá gerar previsões diferentes que podem ser analisadas.

	Currency	Price	24h Open (USD)	24h High (USD)	24h Low (USD)	Predictions
Date						
2016-06-27	BTC	644.091000	657.223990	659.692000	615.775000	644.091000
2016-06-28	BTC	655.943990	644.091000	661.352990	626.160990	644.091000
2016-06-29	BTC	634.357000	655.943990	656.006000	624.768000	644.091000
2016-06-30	BTC	635.093000	634.357000	642.485000	627.687000	644.091000
2016-07-01	BTC	683.293000	635.093000	684.652000	634.987000	644.091000
...
2020-11-27	BTC	17023.961400	17180.718730	17482.200105	16489.302666	16747.705715
2020-11-28	BTC	17814.780278	17159.109497	17901.382623	16906.176104	16473.404569
2020-11-29	BTC	18114.414349	17742.823039	18356.313227	17545.196217	17119.478993
2020-11-30	BTC	19382.360586	18201.277248	19850.114487	18201.277248	17449.638249
2020-12-01	BTC	18980.977450	19677.989844	19920.534263	18171.750511	18090.268972

1608 rows × 6 columns

Figura 6. Resultados da introdução de dados ao modelo gerado pela rede natural.

5.2. Análise

Para analisar os resultados de uma forma mais intuitiva, foi gerado um gráfico, este gráfico pode ser visualizado na figura 7. Como você pode ver, a linha azul representa o valor original de nossos dados e a linha vermelha os resultados obtidos por nosso modelo.

Também podemos ver que os resultados parecem bastante bons, mas para uma análise mais formal usaremos duas métricas. A primeira é obter o erro percentual médio entre o preço original e as previsões em grupos de 500 dias e a segunda métrica é calcular quantas vezes o preço real está dentro de uma certa margem de erro perto da previsão,



Figura 7. Comparação dos resultados reais e previstos.

por exemplo, se nossa previsão é 200 e o preço real é 215, podemos dizer que a previsão estava correta se a margem de erro fosse +/- 10%.

Os resultados dessas 2 métricas são mostrados na tabela 1, os resultados 0-500 representam os resultados mais recentes. A linha "MAPE" é o erro percentual médio, o que nos diz que quanto menor o valor melhor, nos 1000 dias mais recentes os valores estão entre 3,8% e 4,3% que são baixos e portanto esses resultados são bons, após que tende a subir nos 1000-1500 dias para 21% e piora drasticamente nos últimos 500 dias.

As outras 3 linhas apresentam a porcentagem do número de vezes que o preço de nossa previsão está dentro de um raio ou margem de erro. Como pode ser visto para as 500 previsões mais recentes eles geram bons resultados exceto por o margem de erro de 5% que apenas 78,4% está dentro desta margem. Nesta métrica algo muito curioso acontece, entre 1000 - 1500 dias Mais recentemente, as porcentagens são piores do que 1500 - 2000, isso acontece porque nosso conjunto de dados inclui apenas 1.608 registros, então segue-se que entre esses dias há apenas 108 registros analisados.

Tabela 1. Resultados do erro percentual médio e margem de erro.

Variáveis	0 - 500	500 - 1000	1000 - 1500	1500 - 2000
MAPE	3.800966	4.286113	21.304657	71.676008
Ratio 15%	99.800000	98.600000	58.000000	82.400000
Ratio 10%	98.000000	92.800000	51.000000	81.200000
Ratio 5%	78.400000	73.600000	33.000000	66.200000

Por fim iremos criar uma coluna de volatilidade (média do desvio padrão dos retornos), este gráfico pode ser visto na figura 8. Aqui você pode ver um grande pico entre 2017-07 e 2018-7 e essa é a razão pela qual o erro percentual médio começa a piorar de 1000-2000. Pode-se observar também que o comportamento da volatilidade do Bitcoin é cíclico, o que poderia auxiliar outros tipos de análises.




Figura 8. Volatilidade do Bitcoin.

6. Conclusões

O objetivo deste trabalho foi criar uma rede neural que possa gerar um modelo adequado para a predição da moeda digital Bitcoin. Conforme visto no documento, os resultados obtidos atendem ao objetivo principal.

Neste trabalho, foram apresentados os componentes necessários para gerar um modelo preditivo de uma moeda digital. Em partículas Bitcoin, pois é a moeda digital mais famosa.

O Bitcoin é uma moeda digital que, como visto, tem um comportamento diferente das moedas comuns, isso porque seus valores de câmbio são muito elevados, se comparados às moedas normais.

A alta volatilidade desta moeda digital faz com que o modelo preditivo gerado não seja muito bom, caso se aplique os mesmos conceitos a moedas com menor volatilidade, pode-se gerar um modelo mais preciso.

A criptomoeda Bitcoin tem crescido muito ao longo dos anos. Nem os mais otimistas há 10 anos imaginam que essa moeda digital valeria tanto.

O modelo gerado pode ser usado para prever o valor do Bitcoin para datas futuras, isso seria útil para quem deseja investir nesta moeda digital.

Os resultados apresentados podem melhorar com uma análise mais aprofundada dos parâmetros usados na rede neural.

Este artigo pode servir de base para a previsão de outras moedas digitais.

Referências

Capítulo 51 - arquitetura de redes neurais long short term memory (lstm) - deep learning book. <http://deeplearningbook.com.br/arquitetura-de-redes-neurais-long-short-term-memory/>. Accessed: 2020-12-08.

Lo que impulsa la volatilidad de la moneda del mercado emergente. <https://www.toptal.com/finance/financial-analysts/por-que-las-monedas-de-mercados-emergentes-son-volatiles>. Accessed: 2020-12-08.

Presente y futuro de las monedas digitales. https://elpais.com/economia/2019/04/10/actualidad/1554908211_323035.html. Accessed: 2020-12-08.

¿qué es y cómo funciona el bitcoin? ¿cómo operar con btc? <https://admiralmarkets.com/es/education/articles/cryptocurrencies/que-es-un-bitcoin>. Accessed: 2020-12-08.

Sak, H., Senior, A. W., and Beaufays, F. (2014). Long short-term memory recurrent neural network architectures for large scale acoustic modeling.

Ulrich, F. (1892). Bitcoin-a moeda na era digital. *Journal*, volume, 2:239.